

NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:



- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje (robovi, texture), pridobljeno na ImageNetu. Ker je zamrznjen, računsko optimiziramo učenje.
- Optimizator: Adam (Prilagodljivi algoritem z momentumom)
Utemeljitev: Izbran zaradi samodejnega prilagajanja hitrosti učenja za vsako utež posebej, kar drastično pospeši konvergenco zadnjega sloja.
- Velikost paketa (Batch Size): 32
Utemeljitev: Vrednost 32 si ogleda dovolj slik hkrati za stabilen korak, a vnaša ravno prav 'šuma', da se Adam ne zatakne v lokalnih minimumih.
- Dolžina učenja: 10 epoh

SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.01):

- Delovanje: Model iz nule izvaja zelo agresivne, velike popravke uteži.
- Pričakovani rezultati na grafih: Natančnost bo verjetno skočila zelo visoko že v prvih epohah. Vendar pa zaradi prevelikih korakov pričakujemo nihanje (cik-cak) krivulj v kasnejših epohah. Obstaja resna nevarnost preučenja (overfittingsa), kjer učna izguba pada, validacijska pa začne naraščati.

REZULTATI POSKUSA:

- Učna izguba: 0.0175 | Učna natančnost: 99.70%
- Val. izguba: 0.0414 | Val. natančnost: 98.62%



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:

- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje (robovi, teksture), pridobljeno na ImageNetu. Ker je zamrznjen, računsko optimiziramo učenje.
- Optimizator: Adam (Prilagodljivi algoritem z momentumom)
Utemeljitev: Izbran zaradi samodejnega prilagajanja hitrosti učenja za vsako utež posebej, kar drastično pospeši konvergenco zadnjega sloja.
- Velikost paketa (Batch Size): 32
Utemeljitev: Vrednost 32 si ogleda dovolj slik hkrati za stabilen korak, a vnaša ravno prav 'šuma', da se Adam ne zatakne v lokalnih minimumih.
- Dolžina učenja: 10 epoh


SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.001):

- Delovanje: Nastavitev predstavlja industrijski standard ('sweet spot') za Adam.
- Pričakovani rezultati na grafih: Pričakujemo šolski primer stabilnega učenja. Izguba (Loss) bi morala enakomerno in gladko padati skozi epohe, natančnost na validacijski množici pa zanesljivo rasti. Model bi moral doseči optimalno konvergenco (točko ravnovesja) brez znakov hude preučenosti.


REZULTATI POSKUSA:

- Učna izguba: 0.0595 | Učna natančnost: 99.40%
- Val. izguba: 0.0521 | Val. natančnost: 100.00%

Zgodovina izgub



Zgodovina natančnosti



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:

- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje (robovi, texture), pridobljeno na ImageNetu. Ker je zamrznjen, računsko optimiziramo učenje.
- Optimizator: Adam (Prilagodljivi algoritem z momentumom)
Utemeljitev: Izbran zaradi samodejnega prilagajanja hitrosti učenja za vsako utež posebej, kar drastično pospeši konvergenco zadnjega sloja.
- Velikost paketa (Batch Size): 32
Utemeljitev: Vrednost 32 si ogleda dovolj slik hkrati za stabilen korak, a vnaša ravno prav 'šuma', da se Adam ne zatakne v lokalnih minimumih.
- Dolžina učenja: 10 epoh


SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.0001):

- Delovanje: Model iz nule izvaja izjemno previdne, mikroskopske popravke uteži.
- Pričakovani rezultati na grafih: Krivulje bodo maksimalno zglajene in brez kakršnih koli šumnih nihanj. Ker pa je model ponastavljen in začenja iz nič, bo napredek počasnejši. Graf bo verjetno nakazal stabilno rast, a bo hkrati pokazal, da bi model za polni potencial potreboval več kot le 10 epoh.


REZULTATI POSKUSA:

- Učna izguba: 0.3956 | Učna natančnost: 95.73%
- Val. izguba: 0.4606 | Val. natančnost: 91.24%

Zgodovina izgub



Zgodovina natančnosti



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:



- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje (robovi, texture), pridobljeno na ImageNetu. Ker je zamrznjen, računsko optimiziramo učenje.
- Optimizator: SGD (Stochastic Gradient Descent)
Utemeljitev: Klasični optimizator, ki posodablja uteži z enakomernim korakom. Zagotavlja stabilno učenje, a zahteva pravilno začetno stopnjo.
- Velikost paketa (Batch Size): 32
Utemeljitev: Vrednost 32 nudi dober kompromis med natančnostjo gradienta in hitrostjo procesiranja posamezne epohe.
- Dolžina učenja: 10 epoh

SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.01):

- Delovanje: Ker SGD nima lastnega pospeševanja, je stopnja 0.01 idealna za prenosno učenje, saj omogoča dovolj velike korake za opazen napredek.
- Pričakovani rezultati na grafih: Pričakujemo enakomeren padec izgube in lepo rast natančnosti skozi vseh 10 epoh. Ker je paket razmeroma majhen (32), lahko krivulje kažejo nekaj malega šuma (cik-cak skokov), kar pa je za SGD povsem običajno.

REZULTATI POSKUSA:

- Učna izguba: 0.0817 | Učna natančnost: 99.01%
- Val. izguba: 0.0703 | Val. natančnost: 100.00%



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:



- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje (robovi, texture), pridobljeno na ImageNetu. Ker je zamrznjen, računsko optimiziramo učenje.
- Optimizator: SGD (Stochastic Gradient Descent)
Utemeljitev: Klasični optimizator, ki posodablja uteži z enakomernim korakom. Zagotavlja stabilno učenje, a zahteva pravilno začetno stopnjo.
- Velikost paketa (Batch Size): 32
Utemeljitev: Vrednost 32 nudi dober kompromis med natančnostjo gradienta in hitrostjo procesiranja posamezne epohe.
- Dolžina učenja: 10 epoh

SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.001):

- Delovanje: Model iz nule izvaja 10-krat manjše in bolj previdne korake kot prej.
- Pričakovani rezultati na grafih: Krivulja izgube bo padala bolj gladko in z manj nihanja kot pri LR 0.01. Vendar pa zaradi manjših korakov obstaja možnost, da bo natančnost naraščala opazno počasneje, saj SGD nima dinamike za hitro pospeševanje.

REZULTATI POSKUSA:

- Učna izguba: 0.3695 | Učna natančnost: 95.93%
- Val. izguba: 0.4030 | Val. natančnost: 94.47%



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:

- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje (robovi, teksture), pridobljeno na ImageNetu. Ker je zamrznjen, računsko optimiziramo učenje.
- Optimizator: SGD (Stochastic Gradient Descent)
Utemeljitev: Klasični optimizator, ki posodablja uteži z enakomernim korakom. Zagotavlja stabilno učenje, a zahteva pravilno začetno stopnjo.
- Velikost paketa (Batch Size): 32
Utemeljitev: Vrednost 32 nudi dober kompromis med natančnostjo gradienta in hitrostjo procesiranja posamezne epohe.
- Dolžina učenja: 10 epoh

SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.0001):

- Delovanje: Model iz nule izvaja mikroskopske, preveč konzervativne korake.
- Pričakovani rezultati na grafih: To bo klasičen primer podučenosti (underfitting). Ker model začneja trenirati iz nič, so koraki optimizatorja SGD enostavno premajhni, da bi se model v 10 epohah premaknil proti optimumu. Graf izgube bo ostal skoraj popolnoma raven, natančnost pa bo blizu naključnega ugibanja.

Ta poskus empirično dokazuje, da SGD nujno potrebuje višji LR ali več epoh.

REZULTATI POSKUSA:

- Učna izguba: 0.9047 | Učna natančnost: 65.04%
- Val. izguba: 0.9235 | Val. natančnost: 62.21%

