

NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:



- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje (robovi, texture), pridobljeno na ImageNetu. Ker je zamrznjen, računsko optimiziramo učenje.
- Optimizator: Adam (Prilagodljivi algoritem z momentumom)
Utemeljitev: Izbran zaradi samodejnega prilagajanja hitrosti učenja za vsako utež posebej, kar drastično pospeši konvergenco zadnjega sloja.
- Velikost paketa (Batch Size): 32
Utemeljitev: Vrednost 32 si ogleda dovolj slik hkrati za stabilen korak, a vnaša ravno prav 'šuma', da se Adam ne zatakne v lokalnih minimumih.
- Dolžina učenja: 10 epoh

SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.01):

- Delovanje: Model iz nule izvaja zelo agresivne, velike popravke uteži.
- Pričakovani rezultati na grafih: Natančnost bo verjetno skočila zelo visoko že v prvih epohah. Vendar pa zaradi prevelikih korakov pričakujemo nihanje (cik-cak) krivulj v kasnejših epohah. Obstaja resna nevarnost preučenja (overfittingsa), kjer učna izguba pada, validacijska pa začne naraščati.

REZULTATI POSKUSA:

- Učna izguba: 0.0175 | Učna natančnost: 99.70%
- Val. izguba: 0.0414 | Val. natančnost: 98.62%



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:

- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje (robovi, texture), pridobljeno na ImageNetu. Ker je zamrznjen, računsko optimiziramo učenje.
- Optimizator: Adam (Prilagodljivi algoritem z momentumom)
Utemeljitev: Izbran zaradi samodejnega prilagajanja hitrosti učenja za vsako utež posebej, kar drastično pospeši konvergenco zadnjega sloja.
- Velikost paketa (Batch Size): 32
Utemeljitev: Vrednost 32 si ogleda dovolj slik hkrati za stabilen korak, a vnaša ravno prav 'šuma', da se Adam ne zatakne v lokalnih minimumih.
- Dolžina učenja: 10 epoh


SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.001):

- Delovanje: Nastavitev predstavlja industrijski standard ('sweet spot') za Adam.
- Pričakovani rezultati na grafih: Pričakujemo šolski primer stabilnega učenja. Izguba (Loss) bi morala enakomerno in gladko padati skozi epohe, natančnost na validacijski množici pa zanesljivo rasti. Model bi moral doseči optimalno konvergenco (točko ravnovesja) brez znakov hude preučenosti.


REZULTATI POSKUSA:

- Učna izguba: 0.0595 | Učna natančnost: 99.40%
- Val. izguba: 0.0521 | Val. natančnost: 100.00%

Zgodovina izgub



Zgodovina natančnosti



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:

- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje (robovi, texture), pridobljeno na ImageNetu. Ker je zamrznjen, računsko optimiziramo učenje.
- Optimizator: Adam (Prilagodljivi algoritem z momentumom)
Utemeljitev: Izbran zaradi samodejnega prilagajanja hitrosti učenja za vsako utež posebej, kar drastično pospeši konvergenco zadnjega sloja.
- Velikost paketa (Batch Size): 32
Utemeljitev: Vrednost 32 si ogleda dovolj slik hkrati za stabilen korak, a vnaša ravno prav 'šuma', da se Adam ne zatakne v lokalnih minimumih.
- Dolžina učenja: 10 epoh


SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.0001):

- Delovanje: Model iz nule izvaja izjemno previdne, mikroskopske popravke uteži.
- Pričakovani rezultati na grafih: Krivulje bodo maksimalno zglajene in brez kakršnih koli šumnih nihanj. Ker pa je model ponastavljen in začenja iz nič, bo napredek počasnejši. Graf bo verjetno nakazal stabilno rast, a bo hkrati pokazal, da bi model za polni potencial potreboval več kot le 10 epoh.


REZULTATI POSKUSA:

- Učna izguba: 0.3956 | Učna natančnost: 95.73%
- Val. izguba: 0.4606 | Val. natančnost: 91.24%

Zgodovina izgub



Zgodovina natančnosti



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:



- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje (robovi, texture), pridobljeno na ImageNetu. Ker je zamrznjen, računsko optimiziramo učenje.
- Optimizator: SGD (Stochastic Gradient Descent)
Utemeljitev: Klasični optimizator, ki posodablja uteži z enakomernim korakom. Zagotavlja stabilno učenje, a zahteva pravilno začetno stopnjo.
- Velikost paketa (Batch Size): 32
Utemeljitev: Vrednost 32 nudi dober kompromis med natančnostjo gradienta in hitrostjo procesiranja posamezne epohe.
- Dolžina učenja: 10 epoh

SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.01):

- Delovanje: Ker SGD nima lastnega pospeševanja, je stopnja 0.01 idealna za prenosno učenje, saj omogoča dovolj velike korake za opazen napredek.
- Pričakovani rezultati na grafih: Pričakujemo enakomeren padec izgube in lepo rast natančnosti skozi vseh 10 epoh. Ker je paket razmeroma majhen (32), lahko krivulje kažejo nekaj malega šuma (cik-cak skokov), kar pa je za SGD povsem običajno.

REZULTATI POSKUSA:

- Učna izguba: 0.0817 | Učna natančnost: 99.01%
- Val. izguba: 0.0703 | Val. natančnost: 100.00%



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:

- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje (robovi, texture), pridobljeno na ImageNetu. Ker je zamrznjen, računsko optimiziramo učenje.
- Optimizator: SGD (Stochastic Gradient Descent)
Utemeljitev: Klasični optimizator, ki posodablja uteži z enakomernim korakom. Zagotavlja stabilno učenje, a zahteva pravilno začetno stopnjo.
- Velikost paketa (Batch Size): 32
Utemeljitev: Vrednost 32 nudi dober kompromis med natančnostjo gradienta in hitrostjo procesiranja posamezne epohe.
- Dolžina učenja: 10 epoh


SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.001):

- Delovanje: Model iz nule izvaja 10-krat manjše in bolj previdne korake kot prej.
- Pričakovani rezultati na grafih: Krivulja izgube bo padala bolj gladko in z manj nihanja kot pri LR 0.01. Vendar pa zaradi manjših korakov obstaja možnost, da bo natančnost naraščala opazno počasneje, saj SGD nima dinamike za hitro pospeševanje.


REZULTATI POSKUSA:

- Učna izguba: 0.3695 | Učna natančnost: 95.93%
- Val. izguba: 0.4030 | Val. natančnost: 94.47%

Zgodovina izgub



Zgodovina natančnosti



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:

- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje (robovi, teksture), pridobljeno na ImageNetu. Ker je zamrznjen, računsko optimiziramo učenje.
- Optimizator: SGD (Stochastic Gradient Descent)
Utemeljitev: Klasični optimizator, ki posodablja uteži z enakomernim korakom. Zagotavlja stabilno učenje, a zahteva pravilno začetno stopnjo.
- Velikost paketa (Batch Size): 32
Utemeljitev: Vrednost 32 nudi dober kompromis med natančnostjo gradienta in hitrostjo procesiranja posamezne epohe.
- Dolžina učenja: 10 epoh



SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.0001):

- Delovanje: Model iz nule izvaja mikroskopske, preveč konzervativne korake.
- Pričakovani rezultati na grafih: To bo klasičen primer podučenosti (underfitting). Ker model začneja trenirati iz nič, so koraki optimizatorja SGD enostavno premajhni, da bi se model v 10 epohah premaknil proti optimumu. Graf izgube bo ostal skoraj popolnoma raven, natančnost pa bo blizu naključnega ugibanja.

Ta poskus empirično dokazuje, da SGD nujno potrebuje višji LR ali več epoh.

REZULTATI POSKUSA:

- Učna izguba: 0.9047 | Učna natančnost: 65.04%
- Val. izguba: 0.9235 | Val. natančnost: 62.21%



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:

- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje, pridobljeno na ImageNetu.
Ker je zamrznjen, učenje poteka hitro in brez prevelike porabe virov.
- Optimizator: Adam (Adam)
Utemeljitev: Izbran zaradi dinamičnega prilagajanja hitrosti učenja za vsako utež posebej, kar drastično pospeši konvergenco zadnjega sloja.
- Velikost paketa (Batch Size): 64
Utemeljitev: Povečanje paketa na 64 stabilizira oceno gradienta. Model si ogleda več slik hkrati, kar zmanjša šum in stabilizira smer učenja.
- Dolžina učenja: 10 epoh


SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.01):

- Delovanje: Model iz nule izvaja agresivne popravke uteži ob stabilnejših gradientih.
- Pričakovani rezultati na grafih: Večja velikost paketa (64) bo nekoliko ublažila tipična Adamova divjanja pri visokem LR (0.01). Krivulje bodo opazno bolj gladke kot pri batch size 32, vendar nevarnost za preučenje (overfitting) ostaja visoka, saj lahko model zaradi agresivnih korakov prehitro preuči učne podatke.


REZULTATI POSKUSA:

- Učna izguba: 0.0215 | Učna natančnost: 99.50%
- Val. izguba: 0.0269 | Val. natančnost: 100.00%

Zgodovina izgub



Zgodovina natančnosti



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:

- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje, pridobljeno na ImageNetu.
Ker je zamrznjen, učenje poteka hitro in brez prevelike porabe virov.
- Optimizator: Adam (Adam)
Utemeljitev: Izbran zaradi dinamičnega prilagajanja hitrosti učenja za vsako utež posebej, kar drastično pospeši konvergenco zadnjega sloja.
- Velikost paketa (Batch Size): 64
Utemeljitev: Povečanje paketa na 64 stabilizira oceno gradienta. Model si ogleda več slik hkrati, cream zmanjša šum in stabilizira smer učenja.
- Dolžina učenja: 10 epoh


SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.001):

- Delovanje: Kombinacija optimalnega koraka (0.001) in stabilnejšega paketa (64).
- Pričakovani rezultati na grafih: To je eden izmed glavnih kandidatov za zmagovalni model. Pričakujemo izjemno čiste, šolske krivulje, kjer bo izguba gladko padala brez šumnih skokov, natančnost pa bo hitro dosegla visok in stabilen plato. Večji paket zagotavlja optimalno posploševanje znanja brez nevarnosti za zgodnji overfitting.


REZULTATI POSKUSA:

- Učna izguba: 0.0883 | Učna natančnost: 99.30%
- Val. izguba: 0.0988 | Val. natančnost: 100.00%

Zgodovina izgub



Zgodovina natančnosti



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:

- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje, pridobljeno na ImageNetu.
Ker je zamrznjen, učenje poteka hitro in brez prevelike porabe virov.
- Optimizator: Adam (Adam)
Utemeljitev: Izbran zaradi dinamičnega prilagajanja hitrosti učenja za vsako utež posebej, kar drastično pospeši konvergenco zadnjega sloja.
- Velikost paketa (Batch Size): 64
Utemeljitev: Povečanje paketa na 64 stabilizira oceno gradienta. Model si ogleda več slik hkrati, cream zmanjša šum in stabilizira smer učenja.
- Dolžina učenja: 10 epoh


SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.0001):

- Delovanje: Model iz nule izvaja mikroskopske popravke pri manjša številu korakov.
- Pričakovani rezultati na grafih: Krivulje bodo popolnoma gladke in stabilne.
Ker pa večji paket (64) zmanjša skupno število posodobitev uteži na epoho, nizek LR pa dela majhne korake, bo učenje precej počasno. Model bo lepo napredoval, vendar bo graf jasno pokazal, da je 10 epoh premalo, da bi pri teh nastavitvah iztisnili maksimum iz mreže.


REZULTATI POSKUSA:

- Učna izguba: 0.5709 | Učna natančnost: 92.25%
- Val. izguba: 0.5974 | Val. natančnost: 88.02%

Zgodovina izgub



Zgodovina natančnosti



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:

- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje, pridobljeno na ImageNetu.
Ker je zamrznjen, učenje poteka hitro in brez prevelike porabe virov.
- Optimizator: SGD (Stochastic Gradient Descent)
Utemeljitev: Klasični algoritem, ki posodablja uteži z enakomernim korakom.
Zahteva dovolj veliko stopnjo učenja, da premaga manjšo frekvenco korakov.
- Velikost paketa (Batch Size): 64
Utemeljitev: Povečanje paketa na 64 stabilizira oceno gradienta. Model si ogleda več slik hkrati, kar zmanjša šum in stabilizira smer učenja.
- Dolžina učenja: 10 epoh


SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.01):

- Delovanje: Stopnja 0.01 ponuja dovolj velike korake, da kompenzira manjše število posodobitev uteži na epoho, ki jih prinaša večji paket (64).
- Pričakovani rezultati na grafih: To bo verjetno najboljši poskus v tej SGD seriji. Krivulje izgube (Loss) in natančnosti (Accuracy) bodo opazno bolj gladke in z manj cik-cak nihanja kot pri batch size 32. Model bo lepo in enakomerno konvergiral, saj večji paket deluje kot naravna zaščita pred prehitrim overfittingom.


REZULTATI POSKUSA:

- Učna izguba: 0.1072 | Učna natančnost: 99.70%
- Val. izguba: 0.1261 | Val. natančnost: 99.54%

Zgodovina izgub



Zgodovina natančnosti



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:

- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje, pridobljeno na ImageNetu.
Ker je zamrznjen, učenje poteka hitro in brez prevelike porabe virov.
- Optimizator: SGD (Stochastic Gradient Descent)
Utemeljitev: Klasični algoritem, ki posodablja uteži z enakomernim korakom.
Zahteva dovolj veliko stopnjo učenja, da premaga manjšo frekvenco korakov.
- Velikost paketa (Batch Size): 64
Utemeljitev: Povečanje paketa na 64 stabilizira oceno gradienta. Model si ogleda več slik hkrati, kar zmanjša šum in stabilizira smer učenja.
- Dolžina učenja: 10 epoh


SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.001):

- Delovanje: Model iz nule izvaja previdne korake, pri čemer se uteži zaradi večjega paketa posodabljajo upočasnjeno.
- Pričakovani rezultati na grafih: Krivulje bodo estetsko zelo lepe in stabilne, vendar pa bo napredek opazno počasnejši. Ker klasični SGD nima notranjega pospeška, se bo poznalo, da je model naredil premalo popravkov. Natančnost bo rasla, vendar bo graf nakazal, da bi pri tej kombinaciji nujno potrebovali več kot 10 epoh.


REZULTATI POSKUSA:

- Učna izguba: 0.5490 | Učna natančnost: 93.55%
- Val. izguba: 0.6019 | Val. natančnost: 88.48%

Zgodovina izgub



Zgodovina natančnosti



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:

- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje, pridobljeno na ImageNetu.
Ker je zamrznjen, učenje poteka hitro in brez prevelike porabe virov.
- Optimizator: SGD (Stochastic Gradient Descent)
Utemeljitev: Klasični algoritem, ki posodablja uteži z enakomernim korakom.
Zahteva dovolj veliko stopnjo učenja, da premaga manjšo frekvenco korakov.
- Velikost paketa (Batch Size): 64
Utemeljitev: Povečanje paketa na 64 stabilizira oceno gradienta. Model si ogleda več slik hkrati, kar zmanjša šum in stabilizira smer učenja.
- Dolžina učenja: 10 epoh



SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.0001):

- Delovanje: Model iz nule opravlja mikroskopske korake ob minimalnem številu posodobitev uteži na epoho.
- Pričakovani rezultati na grafih: Tukaj bomo videli še močnejši pojav podučenosti (underfitting) kot pri batch size 32. Ker model začne iz nule, kombinacija majhnega števila korakov (zaradi batch 64) in mikroskopske dolžine koraka (0.0001) pomeni, da se model skoraj ne bo premaknil z mesta. Krivulja izgube bo praktično vodoravna ravna črta, natančnost pa bo zelo nizka.

Ta poskus je ključen dokaz, zakaj je klasični SGD pri nizkih LR neuporaben brez drastičnega povečanja števila epoh.

REZULTATI POSKUSA:

- Učna izguba: 1.0467 | Učna natančnost: 42.80%
- Val. izguba: 1.0874 | Val. natančnost: 37.79%



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:

- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje, pridobljeno na ImageNetu. Obdržimo zamrznjene uteži za maksimalno računsko učinkovitost.
- Optimizator: Adam (Adam)
Utemeljitev: Prilagodljivi optimizator, ki bo s pomočjo lastnega momenta poskusil nadoknaditi majhno število posodobitev uteži, ki jih prinaša velik batch.
- Velikost paketa (Batch Size): 128
Utemeljitev: Maksimalna testirana vrednost (128) poskrbi za izjemno stabilne ocene gradientov in popolnoma zglajen potek učenja.
- Dolžina učenja: 10 epoh


SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.01):

- Delovanje: Model iz nule kombinira zelo visok korak (0.01) z minimalnim številom posodobitev uteži znotraj posamezne epohe.
- Pričakovani rezultati na grafih: Ker batch 128 močno stabilizira učenje, bodo krivulje opazno bolj stabilne kot pri manjših paketih z enakim LR. Kljub temu je 0.01 za Adama zelo agresivna nastavitev. Model bo hitro dosegel visoko natančnost, vendar moramo skrbno spremljati validacijsko izgubo zaradi nevarnosti hitrega odhoda v preučenost (overfitting).


REZULTATI POSKUSA:

- Učna izguba: 0.0258 | Učna natančnost: 99.60%
- Val. izguba: 0.0201 | Val. natančnost: 100.00%

Zgodovina izgub



Zgodovina natančnosti



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:

- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje, pridobljeno na ImageNetu. Obdržimo zamrznjene uteži za maksimalno računsko učinkovitost.
- Optimizator: Adam (Adam)
Utemeljitev: Prilagodljivi optimizator, ki bo s pomočjo lastnega momenta poskusil nadoknaditi majhno število posodobitev uteži, ki jih prinaša velik batch.
- Velikost paketa (Batch Size): 128
Utemeljitev: Maksimalna testirana vrednost (128) poskrbi za izjemno stabilne ocene gradientov in popolnoma zglajen potek učenja.
- Dolžina učenja: 10 epoh


SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.001):

- Delovanje: Teoretično najbolj uravnotežena točka za Adam v kombinaciji z maksimalno stabilnostjo, ki jo prinaša velik paket.
- Pričakovani rezultati na grafih: Pričakujemo izjemno čiste in estetske krivulje, kjer bo izguba (Loss) gladko padala brez kakršnih koli šumnih skokov. Zaradi velikega paketa bo model odlično posploševal znanje (dobra generalizacija). Preverjamo, ali je 10 epoh dovolj, da model ob manjšem številu korakov doseže svoj polni vrh.


REZULTATI POSKUSA:

- Učna izguba: 0.1128 | Učna natančnost: 99.60%
- Val. izguba: 0.1622 | Val. natančnost: 98.62%

Zgodovina izgub



Zgodovina natančnosti



DNEVNIK UCENJA - 2026-05-24 09:33:44

NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:



- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje, pridobljeno na ImageNetu. Obdržimo zamrznjene uteži za maksimalno računsko učinkovitost.
- Optimizator: Adam (Adam)
Utemeljitev: Prilagodljivi optimizator, ki bo s pomočjo lastnega momenta poskusil nadoknaditi majhno število posodobitev uteži, ki jih prinaša velik batch.
- Velikost paketa (Batch Size): 128
Utemeljitev: Maksimalna testirana vrednost (128) poskrbi za izjemno stabilne ocene gradientov in popolnoma zglajen potek učenja.
- Dolžina učenja: 10 epoh

SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.0001):

- Delovanje: Model iz nule opravlja zelo majhne korake (0.0001) ob najnižji frekvenci posodobitev uteži v celotnem eksperimentu.
- Pričakovani rezultati na grafih: Graf bo popolnoma gladek, brez kančka nemira. Vendar pa bo učenje zaradi dveh zavor (nizek LR + malo korakov na epoho) potekalo zelo upočasnjeno. Adam bo sicer zanesljivo vlekel model naprej, a končni rezultat bo jasen pokazatelj, da bi pri teh nastavitvah za resen uspeh potrebovali bistveno več kot le 10 epoh.

REZULTATI POSKUSA:

- Učna izguba:	0.7242		Učna natančnost:	86.69%
- Val. izguba:	0.7772		Val. natančnost:	78.80%



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:

- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje, pridobljeno na ImageNetu. Obdržimo zamrznjene uteži za maksimalno računsko učinkovitost.
- Optimizator: SGD (Stochastic Gradient Descent)
Utemeljitev: Klasični algoritem, ki posodablja uteži z enakomernim korakom. Pri batchu 128 nujno potrebuje višji LR, da sploh premakne model.
- Velikost paketa (Batch Size): 128
Utemeljitev: Maksimalna testirana vrednost (128) drastično zmanjša število posodobitev uteži na epoho, a prinaša izjemno stabilne gradienti.
- Dolžina učenja: 10 epoh


SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.01):

- Delovanje: Relativno velik korak (0.01) skuša nadoknaditi zelo majhno število posodobitev uteži, ki jih v eni epohi opravi velik paket 128.
- Pričakovani rezultati na grafih: To bo najboljši model v tej seriji. Krivulje bodo čudovito zglajene, brez kakršnih koli nihanj ali cik-cak skokov. Natančnost bo enakomerno rasla, izguba pa padala. Velik paket deluje kot odličen stabilizator, zato bo preučenost (overfitting) pri teh nastavitvah minimalna.


REZULTATI POSKUSA:

- Učna izguba: 0.1763 | Učna natančnost: 99.21%
- Val. izguba: 0.2388 | Val. natančnost: 98.62%

Zgodovina izgub



Zgodovina natančnosti



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:

- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje, pridobljeno na ImageNetu. Obdržimo zamrznjene uteži za maksimalno računsko učinkovitost.
- Optimizator: SGD (Stochastic Gradient Descent)
Utemeljitev: Klasični algoritem, ki posodablja uteži z enakomernim korakom. Pri batchu 128 nujno potrebuje višji LR, da sploh premakne model.
- Velikost paketa (Batch Size): 128
Utemeljitev: Maksimalna testirana vrednost (128) drastično zmanjša število posodobitev uteži na epoho, a prinaša izjemno stabilne gradienti.
- Dolžina učenja: 10 epoh


SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.001):

- Delovanje: Previdni koraki (0.001) v kombinaciji z minimalnim številom posodobitev uteži na epoho (zaradi batcha 128).
- Pričakovani rezultati na grafih: Model bo napredoval izjemno počasi. Krivulje bodo estetsko popolnoma gladke, vendar bo naklon padanja izgube zelo nizek. Natančnost bo sicer narasla višje od naključnega ugibanja, vendar bo končni rezultat jasno pokazal podučenost (underfitting) – model bi za resen uspeh potreboval bistveno več epoh.


REZULTATI POSKUSA:

- Učna izguba: 0.7907 | Učna natančnost: 74.58%
- Val. izguba: 0.8045 | Val. natančnost: 71.89%

Zgodovina izgub



Zgodovina natančnosti



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:

- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje, pridobljeno na ImageNetu. Obdržimo zamrznjene uteži za maksimalno računsko učinkovitost.
- Optimizator: SGD (Stochastic Gradient Descent)
Utemeljitev: Klasični algoritem, ki posodablja uteži z enakomernim korakom. Pri batchu 128 nujno potrebuje višji LR, da sploh premakne model.
- Velikost paketa (Batch Size): 128
Utemeljitev: Maksimalna testirana vrednost (128) drastično zmanjša število posodobitev uteži na epoho, a prinaša izjemno stabilne gradienti.
- Dolžina učenja: 10 epoh

SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.0001):


- Delovanje: Najpočasnejša možna konfiguracija v celotnem projektu. Mikroskopski koraki ob minimalnem številu posodobitev uteži.
- Pričakovani rezultati na grafih: Tukaj bomo zabeležili najmočnejši pojav podučenosti (underfitting). Ker klasični SGD nima notranjega pospeška (momenta), kombinacija tako velikega paketa in tako nizkega LR pomeni, da se model praktično ne bo premaknil z izhodiščne točke. Graf izgube bo izgledal kot ravna vodoravna črta, natančnost pa bo ostala zelo nizka.

Ta poskus boslužil kot odličen dokaz ekstremnih omejitev algoritma SGD.


REZULTATI POSKUSA:

- Učna izguba: 1.1132 | Učna natančnost: 33.66%
- Val. izguba: 1.2024 | Val. natančnost: 28.57%

Zgodovina izgub



Zgodovina natančnosti



NASTAVITVE MODELA:

- Optimizator: Adam | LR: 0.01 | Batch Size: 128 | Epohe: 5


RAZLAGA IN UTEMELJITEV HIPERPARAMETROV:

- Velik paket (128) zagotavlja izjemno stabilne in matematično 'čist' gradient, kar modelu omogoča varno uporabo zelo agresivne stopnje učenja (0.01).
- S tem poskusom preverjamo hitrost konvergence: ali lahko ta kombinacija zaradi visokega LR doseže končni vrhunski rezultat že v polovičnem času (5 epoh).


REZULTATI POSKUSA:

- Učna izguba: 0.0461 | Učna natančnost: 99.60%
- Val. izguba: 0.0520 | Val. natančnost: 99.54%

Zgodovina izgub



Zgodovina natančnosti



NASTAVITVE MODELA:

- Optimizator: Adam | LR: 0.01 | Batch Size: 128 | Epohe: 12


RAZLAGA IN UTEMELJITEV HIPERPARAMETROV:

- Podaljšanje učenja na 12 epoh pri visokem LR (0.01) služi kot test stabilnosti. Ker je batch size velik (128), model odlično posplošuje znanje, vendar kombinacija visokega LR in daljšega časa učenja prinaša tveganje za preučenost (overfitting). Na grafu opazujemo, ali bo validacijska izguba začela ponovno rasti.


REZULTATI POSKUSA:

- Učna izguba: 0.0215 | Učna natančnost: 99.40%
- Val. izguba: 0.0252 | Val. natančnost: 100.00%

Zgodovina izgub



Zgodovina natančnosti



NASTAVITVE MODELA:

- Optimizator: Adam | LR: 0.001 | Batch Size: 32 | Epohe: 5


RAZLAGA IN UTEMELJITEV HIPERPARAMETROV:

- Manjši paket (32) vnaša v gradient več statističnega šuma, zato je stopnja učenja nastavljena na varnejših 0.001, kar je industrijski 'sweet spot' za Adama.
- V 5 epohah preverjamo, ali je manjši paket (ki izvede več popravkov na epoho kot batch 128) sposoben hitreje kompenzirati nižji LR in doseči stabilno natančnost že na začetku.


REZULTATI POSKUSA:

- Učna izguba: 0.1173 | Učna natančnost: 99.21%
- Val. izguba: 0.1301 | Val. natančnost: 97.70%

Zgodovina izgub



Zgodovina natančnosti



NASTAVITVE MODELA:

- Optimizator: Adam | LR: 0.001 | Batch Size: 32 | Epohe: 12


RAZLAGA IN UTEMELJITEV HIPERPARAMETROV:

- Model pustimo teči 12 epoh z namenom, da preverimo končni domet te optimalne konfiguracije. Ker se model uči zelo natančno, preverjamo, ali bo krivulja izgube na validaciji dosegla popoln in raven plato, kar bi pomenilo idealno natreniran model.


REZULTATI POSKUSA:

- Učna izguba: 0.0528 | Učna natančnost: 99.40%
- Val. izguba: 0.0427 | Val. natančnost: 100.00%

Zgodovina izgub



Zgodovina natančnosti



NASTAVITVE MODELA:

- Optimizator: SGD | LR: 0.01 | Batch Size: 64 | Epohe: 5


RAZLAGA IN UTEMELJITEV HIPERPARAMETROV:

- Klasični SGD nima dinamičnega pospeška, zato je stopnja 0.01 ključna, da ima model dovolj 'pogona'. Batch size 64 nudi odlično ravnoesje med stabilnostjo in šumnostjo.
- Pri 5 epohah pričakujemo, da bo SGD zaradi linearnega načina učenja pokazal nekoliko slabše rezultate kot Adam, saj potrebuje več časa za ogrevanje uteži.


REZULTATI POSKUSA:

- Učna izguba: 0.1893 | Učna natančnost: 98.81%
- Val. izguba: 0.2066 | Val. natančnost: 99.08%

Zgodovina izgub



Zgodovina natančnosti



NASTAVITVE MODELA:

- Optimizator: SGD | LR: 0.01 | Batch Size: 64 | Epohe: 12


RAZLAGA IN UTEMELJITEV HIPERPARAMETROV:

- Ker se SGD uči enakomerno, mu dodatni epoho (skupaj 12) ponujata idealno priložnost, da doseže svoj polni potencial. Preverjamo, ali bo krivulja validacijske izgube še vedno enakomerno padala, kar bi potrdilo, da je SGD bolj varen pred overfittingom kot Adam.


REZULTATI POSKUSA:

- Učna izguba: 0.1105 | Učna natančnost: 98.91%
- Val. izguba: 0.1192 | Val. natančnost: 99.08%

Zgodovina izgub



Zgodovina natančnosti



NASTAVITVE MODELA:

- Optimizator: SGD | LR: 0.01 | Batch Size: 32 | Epohe: 5


RAZLAGA IN UTEMELJITEV HIPERPARAMETROV:

- Ker je paket majhen (32), model izvede največje število posodobitev uteži na epoho. V kombinaciji z visokim LR (0.01) je to učenje izjemno dinamično in hitro.
- Pri 5 epohah preverjamo, ali lahko ta visoka frekvenca korakov omogoči SGD-ju, vseeno hitro doseže visoko natančnost, kljub odsotnosti prilagodljivih mehanizmov.


REZULTATI POSKUSA:

- Učna izguba: 0.1326 | Učna natančnost: 98.51%
- Val. izguba: 0.1251 | Val. natančnost: 100.00%

Zgodovina izgub



Zgodovina natančnosti



NASTAVITVE MODELA:

- Optimizator: SGD | LR: 0.01 | Batch Size: 32 | Epohe: 12


RAZLAGA IN UTEMELJITEV HIPERPARAMETROV:

- Kombinacija majhnega paketa (veliko šuma) in visokega LR skozi 12 epoh predstavlja najbolj nemirno učenje v tej fazi. Na grafih spremljamo cik-cak nihanja. Preverjamo, ali bo model ob koncu 12. epohe zaradi prevelike dinamičnosti začel izgubljati natančnost na validacijski množici.

REZULTATI POSKUSA:

- Učna izguba: 0.0873 | Učna natančnost: 98.41%
- Val. izguba: 0.0655 | Val. natančnost: 100.00%

Zgodovina izgub



Zgodovina natančnosti

