

NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:



- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje (robovi, texture), pridobljeno na ImageNetu. Ker je zamrznjen, računsko optimiziramo učenje.
- Optimizator: Adam (Prilagodljivi algoritem z momentumom)
Utemeljitev: Izbran zaradi samodejnega prilagajanja hitrosti učenja za vsako utež posebej, kar drastično pospeši konvergenco zadnjega sloja.
- Velikost paketa (Batch Size): 32
Utemeljitev: Vrednost 32 si ogleda dovolj slik hkrati za stabilen korak, a vnaša ravno prav 'šuma', da se Adam ne zatakne v lokalnih minimumih.
- Dolžina učenja: 10 epoh

SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.01):

- Delovanje: Model iz nule izvaja zelo agresivne, velike popravke uteži.
- Pričakovani rezultati na grafih: Natančnost bo verjetno skočila zelo visoko že v prvih epohah. Vendar pa zaradi prevelikih korakov pričakujemo nihanje (cik-cak) krivulj v kasnejših epohah. Obstaja resna nevarnost preučenja (overfittingsa), kjer učna izguba pada, validacijska pa začne naraščati.

REZULTATI POSKUSA:

- Učna izguba: 0.0175 | Učna natančnost: 99.70%
- Val. izguba: 0.0414 | Val. natančnost: 98.62%



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:

- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje (robovi, teksture), pridobljeno na ImageNetu. Ker je zamrznjen, računsko optimiziramo učenje.
- Optimizator: Adam (Prilagodljivi algoritem z momentumom)
Utemeljitev: Izbran zaradi samodejnega prilagajanja hitrosti učenja za vsako utež posebej, kar drastično pospeši konvergenco zadnjega sloja.
- Velikost paketa (Batch Size): 32
Utemeljitev: Vrednost 32 si ogleda dovolj slik hkrati za stabilen korak, a vnaša ravno prav 'šuma', da se Adam ne zatakne v lokalnih minimumih.
- Dolžina učenja: 10 epoh


SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.001):

- Delovanje: Nastavitev predstavlja industrijski standard ('sweet spot') za Adam.
- Pričakovani rezultati na grafih: Pričakujemo šolski primer stabilnega učenja. Izguba (Loss) bi morala enakomerno in gladko padati skozi epohe, natančnost na validacijski množici pa zanesljivo rasti. Model bi moral doseči optimalno konvergenco (točko ravnovesja) brez znakov hude preučenosti.


REZULTATI POSKUSA:

- Učna izguba: 0.0595 | Učna natančnost: 99.40%
- Val. izguba: 0.0521 | Val. natančnost: 100.00%

Zgodovina izgub



Zgodovina natančnosti



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:

- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje (robovi, texture), pridobljeno na ImageNetu. Ker je zamrznjen, računsko optimiziramo učenje.
- Optimizator: Adam (Prilagodljivi algoritem z momentumom)
Utemeljitev: Izbran zaradi samodejnega prilagajanja hitrosti učenja za vsako utež posebej, kar drastično pospeši konvergenco zadnjega sloja.
- Velikost paketa (Batch Size): 32
Utemeljitev: Vrednost 32 si ogleda dovolj slik hkrati za stabilen korak, a vnaša ravno prav 'šuma', da se Adam ne zatakne v lokalnih minimumih.
- Dolžina učenja: 10 epoh


SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.0001):

- Delovanje: Model iz nule izvaja izjemno previdne, mikroskopske popravke uteži.
- Pričakovani rezultati na grafih: Krivulje bodo maksimalno zglajene in brez kakršnih koli šumnih nihanj. Ker pa je model ponastavljen in začenja iz nič, bo napredek počasnejši. Graf bo verjetno nakazal stabilno rast, a bo hkrati pokazal, da bi model za polni potencial potreboval več kot le 10 epoh.


REZULTATI POSKUSA:

- Učna izguba: 0.3956 | Učna natančnost: 95.73%
- Val. izguba: 0.4606 | Val. natančnost: 91.24%

Zgodovina izgub



Zgodovina natančnosti



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:

- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje (robovi, texture), pridobljeno na ImageNetu. Ker je zamrznjen, računsko optimiziramo učenje.
- Optimizator: SGD (Stochastic Gradient Descent)
Utemeljitev: Klasični optimizator, ki posodablja uteži z enakomernim korakom. Zagotavlja stabilno učenje, a zahteva pravilno začetno stopnjo.
- Velikost paketa (Batch Size): 32
Utemeljitev: Vrednost 32 nudi dober kompromis med natančnostjo gradienta in hitrostjo procesiranja posamezne epohe.
- Dolžina učenja: 10 epoh


SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.01):

- Delovanje: Ker SGD nima lastnega pospeševanja, je stopnja 0.01 idealna za prenosno učenje, saj omogoča dovolj velike korake za opazen napredek.
- Pričakovani rezultati na grafih: Pričakujemo enakomeren padec izgube in lepo rast natančnosti skozi vseh 10 epoh. Ker je paket razmeroma majhen (32), lahko krivulje kažejo nekaj malega šuma (cik-cak skokov), kar pa je za SGD povsem običajno.


REZULTATI POSKUSA:

- Učna izguba: 0.0817 | Učna natančnost: 99.01%
- Val. izguba: 0.0703 | Val. natančnost: 100.00%

Zgodovina izgub



Zgodovina natančnosti



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:



- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje (robovi, texture), pridobljeno na ImageNetu. Ker je zamrznjen, računsko optimiziramo učenje.
- Optimizator: SGD (Stochastic Gradient Descent)
Utemeljitev: Klasični optimizator, ki posodablja uteži z enakomernim korakom. Zagotavlja stabilno učenje, a zahteva pravilno začetno stopnjo.
- Velikost paketa (Batch Size): 32
Utemeljitev: Vrednost 32 nudi dober kompromis med natančnostjo gradienta in hitrostjo procesiranja posamezne epohe.
- Dolžina učenja: 10 epoh

SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.001):

- Delovanje: Model iz nule izvaja 10-krat manjše in bolj previdne korake kot prej.
- Pričakovani rezultati na grafih: Krivulja izgube bo padala bolj gladko in z manj nihanja kot pri LR 0.01. Vendar pa zaradi manjših korakov obstaja možnost, da bo natančnost naraščala opazno počasneje, saj SGD nima dinamike za hitro pospeševanje.

REZULTATI POSKUSA:

- Učna izguba: 0.3695 | Učna natančnost: 95.93%
- Val. izguba: 0.4030 | Val. natančnost: 94.47%



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:

- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje (robovi, teksture), pridobljeno na ImageNetu. Ker je zamrznjen, računsko optimiziramo učenje.
- Optimizator: SGD (Stochastic Gradient Descent)
Utemeljitev: Klasični optimizator, ki posodablja uteži z enakomernim korakom. Zagotavlja stabilno učenje, a zahteva pravilno začetno stopnjo.
- Velikost paketa (Batch Size): 32
Utemeljitev: Vrednost 32 nudi dober kompromis med natančnostjo gradienta in hitrostjo procesiranja posamezne epohe.
- Dolžina učenja: 10 epoh



SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.0001):

- Delovanje: Model iz nule izvaja mikroskopske, preveč konzervativne korake.
- Pričakovani rezultati na grafih: To bo klasičen primer podučenosti (underfitting). Ker model začneja trenirati iz nič, so koraki optimizatorja SGD enostavno premajhni, da bi se model v 10 epohah premaknil proti optimumu. Graf izgube bo ostal skoraj popolnoma raven, natančnost pa bo blizu naključnega ugibanja.

Ta poskus empirično dokazuje, da SGD nujno potrebuje višji LR ali več epoh.

REZULTATI POSKUSA:

- Učna izguba: 0.9047 | Učna natančnost: 65.04%
- Val. izguba: 0.9235 | Val. natančnost: 62.21%



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:

- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje, pridobljeno na ImageNetu.
Ker je zamrznjen, učenje poteka hitro in brez prevelike porabe virov.
- Optimizator: Adam (Adam)
Utemeljitev: Izbran zaradi dinamičnega prilagajanja hitrosti učenja za vsako utež posebej, kar drastično pospeši konvergenco zadnjega sloja.
- Velikost paketa (Batch Size): 64
Utemeljitev: Povečanje paketa na 64 stabilizira oceno gradienta. Model si ogleda več slik hkrati, kar zmanjša šum in stabilizira smer učenja.
- Dolžina učenja: 10 epoh


SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.01):

- Delovanje: Model iz nule izvaja agresivne popravke uteži ob stabilnejših gradientih.
- Pričakovani rezultati na grafih: Večja velikost paketa (64) bo nekoliko ublažila tipična Adamova divjanja pri visokem LR (0.01). Krivulje bodo opazno bolj gladke kot pri batch size 32, vendar nevarnost za preučenje (overfitting) ostaja visoka, saj lahko model zaradi agresivnih korakov prehitro preuči učne podatke.


REZULTATI POSKUSA:

- Učna izguba: 0.0215 | Učna natančnost: 99.50%
- Val. izguba: 0.0269 | Val. natančnost: 100.00%

Zgodovina izgub



Zgodovina natančnosti



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:

- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje, pridobljeno na ImageNetu.
Ker je zamrznjen, učenje poteka hitro in brez prevelike porabe virov.
- Optimizator: Adam (Adam)
Utemeljitev: Izbran zaradi dinamičnega prilagajanja hitrosti učenja za vsako utež posebej, kar drastično pospeši konvergenco zadnjega sloja.
- Velikost paketa (Batch Size): 64
Utemeljitev: Povečanje paketa na 64 stabilizira oceno gradienta. Model si ogleda več slik hkrati, cream zmanjša šum in stabilizira smer učenja.
- Dolžina učenja: 10 epoh


SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.001):

- Delovanje: Kombinacija optimalnega koraka (0.001) in stabilnejšega paketa (64).
- Pričakovani rezultati na grafih: To je eden izmed glavnih kandidatov za zmagovalni model. Pričakujemo izjemno čiste, šolske krivulje, kjer bo izguba gladko padala brez šumnih skokov, natančnost pa bo hitro dosegla visok in stabilen plato. Večji paket zagotavlja optimalno posploševanje znanja brez nevarnosti za zgodnji overfitting.


REZULTATI POSKUSA:

- Učna izguba: 0.0883 | Učna natančnost: 99.30%
- Val. izguba: 0.0988 | Val. natančnost: 100.00%

Zgodovina izgub



Zgodovina natančnosti



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:

- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje, pridobljeno na ImageNetu.
Ker je zamrznjen, učenje poteka hitro in brez prevelike porabe virov.
- Optimizator: Adam (Adam)
Utemeljitev: Izbran zaradi dinamičnega prilagajanja hitrosti učenja za vsako utež posebej, kar drastično pospeši konvergenco zadnjega sloja.
- Velikost paketa (Batch Size): 64
Utemeljitev: Povečanje paketa na 64 stabilizira oceno gradienta. Model si ogleda več slik hkrati, cream zmanjša šum in stabilizira smer učenja.
- Dolžina učenja: 10 epoh


SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.0001):

- Delovanje: Model iz nule izvaja mikroskopske popravke pri manjša številu korakov.
- Pričakovani rezultati na grafih: Krivulje bodo popolnoma gladke in stabilne.
Ker pa večji paket (64) zmanjša skupno število posodobitev uteži na epoho, nizek LR pa dela majhne korake, bo učenje precej počasno. Model bo lepo napredoval, vendar bo graf jasno pokazal, da je 10 epoh premalo, da bi pri teh nastavitvah iztisnili maksimum iz mreže.


REZULTATI POSKUSA:

- Učna izguba: 0.5709 | Učna natančnost: 92.25%
- Val. izguba: 0.5974 | Val. natančnost: 88.02%

Zgodovina izgub



Zgodovina natančnosti



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:

- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje, pridobljeno na ImageNetu.
Ker je zamrznjen, učenje poteka hitro in brez prevelike porabe virov.
- Optimizator: SGD (Stochastic Gradient Descent)
Utemeljitev: Klasični algoritem, ki posodablja uteži z enakomernim korakom.
Zahteva dovolj veliko stopnjo učenja, da premaga manjšo frekvenco korakov.
- Velikost paketa (Batch Size): 64
Utemeljitev: Povečanje paketa na 64 stabilizira oceno gradienta. Model si ogleda več slik hkrati, kar zmanjša šum in stabilizira smer učenja.
- Dolžina učenja: 10 epoh


SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.01):

- Delovanje: Stopnja 0.01 ponuja dovolj velike korake, da kompenzira manjše število posodobitev uteži na epoho, ki jih prinaša večji paket (64).
- Pričakovani rezultati na grafih: To bo verjetno najboljši poskus v tej SGD seriji. Krivulje izgube (Loss) in natančnosti (Accuracy) bodo opazno bolj gladke in z manj cik-cak nihanja kot pri batch size 32. Model bo lepo in enakomerno konvergiral, saj večji paket deluje kot naravna zaščita pred prehitrim overfittingom.


REZULTATI POSKUSA:

- Učna izguba: 0.1072 | Učna natančnost: 99.70%
- Val. izguba: 0.1261 | Val. natančnost: 99.54%

Zgodovina izgub



Zgodovina natančnosti



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:

- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje, pridobljeno na ImageNetu.
Ker je zamrznjen, učenje poteka hitro in brez prevelike porabe virov.
- Optimizator: SGD (Stochastic Gradient Descent)
Utemeljitev: Klasični algoritem, ki posodablja uteži z enakomernim korakom.
Zahteva dovolj veliko stopnjo učenja, da premaga manjšo frekvenco korakov.
- Velikost paketa (Batch Size): 64
Utemeljitev: Povečanje paketa na 64 stabilizira oceno gradienta. Model si ogleda več slik hkrati, kar zmanjša šum in stabilizira smer učenja.
- Dolžina učenja: 10 epoh


SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.001):

- Delovanje: Model iz nule izvaja previdne korake, pri čemer se uteži zaradi večjega paketa posodabljajo upočasnjeno.
- Pričakovani rezultati na grafih: Krivulje bodo estetsko zelo lepe in stabilne, vendar pa bo napredek opazno počasnejši. Ker klasični SGD nima notranjega pospeška, se bo poznalo, da je model naredil premalo popravkov. Natančnost bo rasla, vendar bo graf nakazal, da bi pri tej kombinaciji nujno potrebovali več kot 10 epoh.


REZULTATI POSKUSA:

- Učna izguba: 0.5490 | Učna natančnost: 93.55%
- Val. izguba: 0.6019 | Val. natančnost: 88.48%

Zgodovina izgub



Zgodovina natančnosti



NASTAVITVE MODELA IN STRATEGIJA OPTIMIZACIJE:

- Arhitektura: ResNet18 (Prenosno učenje - zamrznjen trup)
Utemeljitev: Trup mreže zadrži splošno znanje, pridobljeno na ImageNetu.
Ker je zamrznjen, učenje poteka hitro in brez prevelike porabe virov.
- Optimizator: SGD (Stochastic Gradient Descent)
Utemeljitev: Klasični algoritem, ki posodablja uteži z enakomernim korakom.
Zahteva dovolj veliko stopnjo učenja, da premaga manjšo frekvenco korakov.
- Velikost paketa (Batch Size): 64
Utemeljitev: Povečanje paketa na 64 stabilizira oceno gradienta. Model si ogleda več slik hkrati, kar zmanjša šum in stabilizira smer učenja.
- Dolžina učenja: 10 epoh

SPECIFIČNA ANALIZA ZA STOPNJO UCENJA (LR: 0.0001):

- Delovanje: Model iz nule opravlja mikroskopske korake ob minimalnem številu posodobitev uteži na epoho.
- Pričakovani rezultati na grafih: Tukaj bomo videli še močnejši pojav podučenosti (underfitting) kot pri batch size 32. Ker model začne iz nule, kombinacija majhnega števila korakov (zaradi batch 64) in mikroskopske dolžine koraka (0.0001) pomeni, da se model skoraj ne bo premaknil z mesta. Krivulja izgube bo praktično vodoravna ravna črta, natančnost pa bo zelo nizka.

Ta poskus je ključen dokaz, zakaj je klasični SGD pri nizkih LR neuporaben brez drastičnega povečanja števila epoh.

REZULTATI POSKUSA:

- Učna izguba: 1.0467 | Učna natančnost: 42.80%
- Val. izguba: 1.0874 | Val. natančnost: 37.79%

